Feuille de TP N°1

Régression linéaire et logistique avec régularisation

Objectif

L'objectif de ce travail pratique est de

1. Mettre en place un environnement de développement pour le Machine Learning en Python.
2. Comprendre le fonctionnement des modèles de régression linéaire et logistique.
3. Implémenter et comparer des modèles de régression linéaire et logistique avec et sans régularisation (Ridge, Lasso, Elastic Net).
4. Évaluer et interpréter les performances des modèles à l'aide de métriques appropriées.

Description du travail

Ce TP est divisé en deux parties :

- La première est consacrée à la **régression linéaire** sur un jeu de données réel.
- La seconde concerne la **régression logistique** appliquée à un problème de classification binaire.

Les étudiants travailleront en utilisant le langage **Python**, la bibliothèque **scikit-learn**, ainsi que **pandas**, **NumPy** et **Matplotlib** pour la manipulation et la visualisation des données.

1. Mise en place de l'environnement

1. Installer et vérifier l'environnement de développement :
    - Python ≥ 3.10
    - Jupyter Notebook
    - Bibliothèques : numpy, pandas, matplotlib, seaborn, scikit-learn
2. Créer un notebook intitulé **TP1_Regression.ipynb**.
3. Importer les bibliothèques nécessaires et vérifier leur bon fonctionnement

2. Régression Linéaire : Prédiction du salaire en fonction de l'expérience

L'objectif est de construire un modèle de régression linéaire simple pour estimer le salaire en fonction de l'expérience. Dans ce TP, nous utiliserons un jeu de données réel **Salary_Data.csv** disponible sur Kaggle – Employee Salaries Dataset.

Il vous est demandé de :

a. Charger le jeu de données

b. Visualiser la relation entre variables.

c. Diviser les données en ensembles d'apprentissage (70 %) et de test (30 %). Standardiser les variables si nécessaire.

d. Entraîner un modèle de régression linéaire sur l'ensemble d'apprentissage.

e. Prédire les valeurs sur l'ensemble de test.

f. Visualiser les résultats.

g. Calculer et afficher l'erreur quadratique moyenne (MSE)

h. Ajouter les régularisation L1, L2 et Elastic Net (L1 + L2), et comparer les performances